

如图所示，ChatTS 中的框架将合成数据生成和模型训练集成到一个流水线中，确保仅使用合成数据就能有效理解时间序列属性并进行推理。首先，基于基于属性的时间序列生成和 TSEvol，该流水线生成能够捕获复杂数值和文本信息以实现有效多模态对齐的合成数据。然后，这些数据用于训练模型，其中上下文感知的时间序列编码器保留时间序列值，同时将属性与文本语义准确对齐。最后，通过对齐训练和 SFT（第 3.5 节），ChatTS 实现了时间序列编码与文本嵌入之间的精确对齐，并增强了推理能力。

基于属性的时间序列合成方法：

将时间序列属性分为四大类：趋势、周期性、噪声和局部波动，以构建相应的时间序列属性集。

全属性集包括 4 种趋势类型、7 种季节性类型、3 种噪声类型和 19 种局部波动类型。同一类别中的不同属性可以组合。通过组合相同类型的属性，一个时间序列可以包含多个趋势段和若干局部波动（见图 4）。此外，通过组合正弦波，我们可以生成多样化的周期性波动模式。因此，所提出的时间序列生成器理论上可以生成无限多种不同的时间序列，确保属性的丰富性。我们还引入了 GPT 选择器。具体来说，在生成时间序列的属性集时，我们从包含 567 个预定义真实场景指标名称的大型“指标集”中随机采样一个指标，并使用 GPT 根据该指标的实际物理意义和预定义场景从全属性集中选择一个属性子集。这有助于将时间序列与真实世界的物理意义对齐。

然后，属性采样器从属性子集中随机采样一组属性组合。它还根据 GPT 选择器的规则和约束分配具体的数值，如位置和幅度。这些细节存储在“属性池”中，该池记录了时间序列的所有详细信息。最后，时间序列生成器以基于规则的方式创建与属性池中属性完全匹配的时间序列数组。这个过程使我们能够生成具有精确属性描述的多样化合成时间序列。

1. 什么是“基于规则的方式” (Rule-based manner)?

在生成时间序列时，作者没有“训练”一个 AI 模型来学会画曲线，而是直接编写了**程序化的数学公式**来合成序列。这些规则包括：

- **趋势生成规则**：使用线性函数 ($y = kx + b$) 或分段线性函数来控制上升、下降或平稳趋势。
- **周期性生成规则**：通过叠加不同频率和相位的**正弦波** ($y = A \cdot \sin(\omega x + \phi)$) 来构造复杂的季节性波动。
- **噪声生成规则**：调用数学随机数生成器，生成特定分布的**高斯噪声**或**均匀噪声**叠加到序列上。
- **局部波动规则**：在指定的时间点（位置），直接**硬编码**一个向上或向下的脉冲函数（如尖峰、凸起、凹陷），甚至可以直接用公式构造一个类似凸形弧线的特殊形状（如论文图13中的OOD波动）。

结论：这种生成方式完全通过“**预制好的数学函数 + 顺序执行代码**”来实现，不依赖任何随机训练过程。

确保了合成出来的时间序列不仅样式千变万化，而且每一个波峰、每一个数值都绝对忠实于它配套的文字描述

TSEvol:

Evol-Instruct [55] 是一种数据生成方法，通过逐步演化指令提示及其输出，以增强 LLMs 训练数据集的多样性和复杂性。TSEvol 在 Evol-Instruct 的基础上，引入了一种机制，在每个演化步骤中动态地融入时间序列属性（见图 5）。TSEvol 依赖于多变量时间序列的属性池（见第 3.2 节）。此外，为增强模型分析相关性的能力，我们引入了一个相关性池，记录具有相

关属性的时间序列（详见源代码）。在演化过程的每一步，从属性池中随机选择一部分属性，并将其作为额外上下文添加，引导 LLMs 根据演化类型生成关于更广泛时间序列属性的问答对。通过 TSEvol，生成的问答对可以覆盖时间序列中更多的属性，并避免重复问题。我们还添加了一个基于属性的消除器，以确保问答对与时间序列属性匹配。除常用的演化类型外，我们还增加了两种类型：推理（基于推理的问题）和情境（基于情境的问题），以增强模型处理复杂问题的能力。

ChatTS 模型架构：

1. 它的基本结构

在神经网络中，一个“5层MLP”通常包含：

- **输入层**：接收时间序列的一个**补丁（Patch）**。补丁是将整条长序列切分为固定长度（例如长度 P）的小片段。
- **隐藏层（3层左右）**：通过全连接层（Linear层）和非线性激活函数（如 ReLU 或 GELU）进行特征变换和提取。
- **输出层**：输出一个固定维度的向量。
- **推测**：最后的输出维度大概率与 Qwen2.5-14B 模型的词嵌入维度（Embedding Dimension）对齐，通常是 4096 维。这样，时间序列的补丁就能和文本的Token在同一个向量空间中进行拼接和计算。

2. 它在 ChatTS 中的核心作用：模态对齐

ChatTS 的核心理念是“**将时间序列作为一种模态**”。

- **输入侧**：时间序列是一串数值数组；文本是离散的Token序列。LLM本身无法直接理解数值序列的波峰波谷。
- **MLP的作用**：充当**翻译器**。它把补丁中的时序特征（数值变化、波形趋势）转化为高维向量。由于输出维度和文本嵌入维度一致，LLM就能把这些向量当成“特殊的文本Token”来理解。
- **结果**：实现了“时间序列模态”与“自然语言模态”的对齐。

对每个时间序列数组应用标准的 min-max 归一化（0-1 缩放）。然后，对于每个时间序列，我们将归一化参数——“数值缩放因子”（归一化时的缩放因子）和“数值偏移量”（归一化时应用的偏移量）——以文本形式包含在提示中。

训练设置：

3.5.1 大规模对齐训练。在第一阶段，我们使用基于属性的合成时间序列数据进行大规模对齐训练，以在 LLM 内建立文本和时间序列模态之间的初始对齐。此阶段使 ChatTS 能够有效地将文本描述与时间序列属性对齐。在对齐阶段，我们基于一系列手动设计的模板和 LLM 精炼创建了三个大规模训练数据集。UTS 数据集包括单变量时间序列的基本属性描述任务（包括全局和局部属性任务）。MTS-Shape 数据集包含具有全局趋势相关性的多变量数据，旨在增强模型分析多变量相关性的能力。MTS-Local 数据集包含具有相关局部波动的多变量数据，旨在提高模型分析多变量数据局部特征的能力。鉴于 MTS 的特征组合更复杂，我们将 MTS 和 UTS 的训练数据大小比例设置为约 2:1。

3.5.2 监督微调。在第二阶段，我们使用 SFT 来培养 LLM 执行复杂问答和推理任务的能力。

此阶段使用两类主要训练数据：由 TSEvol 生成的数据集，旨在增强模型关于时间序列的问答和推理能力；以及一个指令遵循（IF）数据集，基于一系列预定义模板构建，旨在增强模型遵循特定响应格式的能力。对于 TSEvol，我们使用来自对齐训练的数据集以及 LLM 生成的问答作为种子数据。这些数据集共同训练多模态 LLM，使其能够准确响应时间序列特定的查询并遵循任务指令，增强其处理复杂、上下文驱动的问答和推理任务的能力。明确训练模型学习各种方面，例如最大值/最小值、分段平均值、局部特征（如尖峰位置和幅度）、季节性和趋势幅度，以及单个时间点的原始数值。

实验设置：

2. F1 基础公式

F1 是精确率 (Precision) 与召回率 (Recall) 的调和平均：

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

- **精确率 P**：模型预测为某类的样本里，真正属于该类的比例；
- **召回率 R**：所有真实属于该类的样本中，被模型正确识别的比例。

RAGAS:

输入：将 ChatTS 生成的真实回答，以及人工标注的参考答案（Ground Truth），一起喂给一个外部的“裁判”大语言模型（通常是 GPT-4 或更强大的模型）。

模糊匹配（Fuzzy Matching）：裁判模型不会去做死板的逐字逐句比对（这称为“精确匹配”，如 BLEU 算法）。相反，它会理解两者的语义。

关键词覆盖检查：裁判模型会判断 ChatTS 的回答是否包含了参考答案中所有关键的信息点和逻辑概念。例如：

标准答案：“该序列反映了服务器过载导致的内存泄漏。”

模型回答：“这个时间序列表明系统可能存在内存溢出问题，这可能由高负载引起。”

判断结果：虽然句子结构完全不同，甚至用词不一样，但因为“服务器过载”、“内存泄漏/溢出”等核心语义关键词被覆盖到了，裁判模型会判定该回答合格或高相似度。

The reasoning tasks include inductive reasoning, deductive reasoning, causal reasoning, and comparison reasoning (MCQ2):

- **推理任务**包括归纳推理、演绎推理、因果推理和比较推理 (MCQ2)：